TRABAJO PRACTICO FINAL PROGRAMACION ORIENTADA A OBJETOS

INTRODUCCION

Bases de datos:

Precios claros es un conjunto de datasets realizado a partir de los precios provistos por el gobierno de los productos en las distintas cadenas de supermercados. Este parte de la iniciativa de la Dirección Nacional de Defensa del Consumidor de que los consumidores cuenten con mayor información a la hora de tomar decisiones con respecto a los productos que adquieren. Particularmente estos dataset pertenecen al año 2020, lo cual es importante tener en consideracion a la hora de mirar los precios dada su elevada diferencia con la actualidad.

La base de datos seleccionada cuenta con 6 datasets: uno de productos, uno con las sucursales y 3 con los precios de abril en distintos periodos, los cuales fueron relevados de la página del gobierno mediante técnicas de scraping por Open Data Córdoba, y por otro lado uno adicional que contiene las provincias y codigos de las mismas.

Link: https://www.kaggle.com/datasets/tinnqn/precios-claros-precios-de-argentina?select=sucursales.csv

Variables:

A continuacion se da una breve definicion de cada variable en el dataset precios claros, el cual se utilizara a lo largo de toda la investigacion.

Producto

- `id` , `productos_id` : numero de identificacion del producto.
- `categoria` : categoria del producto (nuestros productos son los que forman parte de la canasta basica: Agua, Leche, Arroz, Harinas y Pastas).
- `marca` : marca del producto.
- `presentacion` : presentacion del producto en cantidad (numeros).
- `unidad_presentacion` : unidad de medida de la presentacion (cc, lt, kg o gr).
- `precio` : precio del producto en el 2020.

Sucursal/Comercio

- `sucursal_id` : numero de identificacion de la sucursal del producto.
- `sucursalTipo` , `tipo_comercio` : tipo de comercio de la sucursal (Supermercado, Hipermercado o Autoservicio).
- `cadena` : es la cadena de supermercado en la que se vende el producto. Este es el target de nuestro modelo, por ello seleccionamos 3 cadenas con distintas categorias: Disco dirigido a personas de alto poder adquisitivo, que es de alta categoria, Hipermercado Carrefour a personas poder adquisitivo medio y Supermercados DIA de menor poder adquisitivo).

Variable dependiente -> es el target mencionado, el cual depende del resto de variables: `cadena` **Variables independientes ->** son las variables que nos van a permitir predecir el target, es decir, todo el resto de variables mencionadas: `categoria`, `marca`, `presentacion`, `unidad_presentacion`, `precio` y `tipo_comercio`.

Objetivo:

El objetivo de este trabajo es poder analizar los precios de los diferentes tipos de productos de la canasta basica, teniendo en cuenta la categoria, marca, tipo de cadena, presentacion y cadena en el que se realiza la venta del producto, para poder evaluar en que comercios y que marcas tienen los productos mas baratos.

Ademas, la idea es crear un modelo de regresion logistica que nos permita predecir en base a las variables a cual cadena pertenece el producto, ya sea Disco, Hipermercado Carrefour o Supermercados DIA. Dado que pertenecen a diferentes categorias de supermercados, sus consumidores objetivo son distintos, por lo que sus precios tambien varian.

Es por eso que el objetivo del modelo es predecir a cual de ellos pertenece el producto.

Hipotesis:

Respecto a las variables seleccionadas se espera poder ver que en el comercio de Disco, dado que es una cadena dirigido a personas de alto poder adquisitivo, sus productos tambien tendran mayores precios. Lo mismo sucedera son Supermercados DIA que al ser una cadena dirigida a consumidores de menor poder adquisitivo que los anteriores, se espera encontrar que sus precios tambien son menores, mientras que en Carrefour se espera encontrar un precio intermedio que en los dos anteriores.

Tranformaciones a realizar:

- **Load & Merge**

En primera instancia se van a cargar todos los datasets, para luego poder unirlos y filtrarlos segun los datos necesarios para el analisi, en este caso, las categorias de productos de canasta basica: Agua, Leche, Arroz, Harinas y Pastas, y la cadena de comercio: Disco, Hipermercado Carrefour y Supermercados Dia. Ademas, como para nuestro modelo necesitamos la columna de presentacion separado de la unidad en la que esta medido, separaremos la columna en esta instancia. El dataframe resultante es el que sera utilizado para el trabajo, el cual se llamara `precios_claros`.

- **Preprocesamiento**

Una vez listo el dataset es necesario realizar un preprocesamiento de los datos. En esta instancia se evaluaran los posibles nulos en nuestras variables realizar el tratamiento adecuado de los mismos (drop, imputer, etc), y se evaluaran tambien los podibles duplicados y outliers.

- **Analisis Inicial**

Se muestar un analisis de nuestros datos, evaluando tendencias, frequencias, etc, con el objetivo de tener un mejor conocimiento de los datos a tratar.

- **Escalado**

Se escalan las variables numericas `precio` y `presentacion` para que sean comparables entre si, a pesar de que su rango de datos en primera instancia sea distinto.

- **Encoding**

Se tratan las variables categorias, creando distintas columnas binarias con la presencia o no de la variable en el producto. Esto es fundamental para el modelo bucado. Ademas, aplicamos el encoding a la variable target.

- **Modelo**

Realizamos el primer modelo de regresion logistica y obtenemos un score mediante un cross validation, el cual se irá mejorando mediante diferentes métodos para lograr un accuracy mas elevado. Haremos una matriz de confusion y veremos accuracy, precision y recall. Ademas haremos la prediccion de una instancia que no existe para probarlo.

In [1]:
```
%load_ext autoreload
%autoreload 2
```

Importamos las librerias que vamos a necesitar.

In [2]:
```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
```

1 - LOAD & MERGE

In [3]:
```
import os
files = [f for f in os.listdir("data/") if f.endswith(".csv")]
print(files)
```

```
['productos_categoria.csv', 'clean_precios_claros.csv', 'precios_20200426_20200426.csv', 'precios_20200412_20200413.csv', 'sucursales.csv', 'precios_20200419_20200419.csv']
```

In [4]:
```
from load_csv_tp import load_all_data
data = load_all_data("data/")
data.keys()
```

Out[4]:
```
dict_keys(['productos_categoria', 'clean_precios_claros', 'precios_20200426_20200426', 'precios_20200412_20200413', 'sucursales', 'precios_20200419_20200419'])
```

Asigno los datasets en variables haciendole una copia para no sobreescribir el original.

Sucursales

In [5]:
```
sucursales = data['sucursales'].copy()
sucursales.head()
```

Out[5]:

	id	comercioId	banderaId	banderaDescripcion	comercioRazonSocial	provincia	localidad	direccion	lat	lng
0	1-1-7	1	1	Super MAMI	Dinosaurio S.A.	AR-X	SALSIPUEDES	E53 1011 None	-31.126667	-64.295250
1	10-1-1	10	1	Hipermercado Carrefour	INC S.A.	AR-B	San Isidro	Bernardo De Irigoyen 2647	-34.491345	-58.589025
2	10-1-10	10	1	Hipermercado Carrefour	INC S.A.	AR-B	Hurlingham	Av. Vergara 1910	-34.620610	-58.633769
3	10-1-11	10	1	Hipermercado Carrefour	INC S.A.	AR-B	Malvinas Argentinas	Av. Arturo Illia 3770	-34.528883	-58.701631
4	10-1-112	10	1	Hipermercado Carrefour	INC S.A.	AR-A	Salta	20 De Febrero 37	-24.789072	-65.413699

Productos

In [6]:
```
productos = data['productos_categoria'].copy()
productos.head()
```

Out[6]:

	_id/$oid	nombre	categoria	marca	presentacion	id
0	5cbc69be7af152186c0cd784	Aceite de Girasol Cañuelas 1.5 Lt	Aceite	CAÑUELAS	1.5 lt	7792180001665
1	5cbc69be7af152186c0cd783	Aceite de Girasol Cañuelas 900 Cc	Aceite	CAÑUELAS	900.0 cc	7792180001641
2	5cbc69be7af152186c0cd54d	Aceite de Girasol Cocinero 1.5 Lt	Aceite	COCINERO	1.5 lt	7790060023684
3	5cbc69be7af152186c0cd552	Aceite de Girasol Cocinero 900 Ml	Aceite	COCINERO	900.0 ml	7790070012050
4	5cbc69be7af152186c0cd5e4	Aceite de Girasol Natura 1.5 Lt	Aceite	NATURA	1.5 lt	7790272001029

Precios

Cargo los datasets de los precios de abril . Como se contaba con varios datasets del mes, se opto por concatenarlos uno debajo del otro para poder tratar los datos y realizar el analisis.

In [7]:
```
precios = pd.concat([data['precios_20200412_20200413'].copy(), data['precios_20200419_20200419'].copy(), data['
precios.head()
```

Out[7]:

	precio	producto_id	sucursal_id
0	29.90	0000000001663	2-1-014
1	29.90	0000000002288	2-1-032
2	39.90	0000000002288	2-1-096
3	499.99	0000000205870	9-1-686
4	519.99	0000000205870	9-2-248

- Merge

Unimos los distintos dataset para pooder realizar el analisis.

Para poder realizarlo en primer lugar voy a establecer como indice de los dataframes los id, con el objetivo de que al unirlo las columnas no se repitan. Y pasamos la columna id de productos a tipo objeto para poder unirla con precios.

In [8]:
```
precios = precios.set_index("producto_id")
sucursales = sucursales.set_index('id')
```

Filtrado de productos

Ademas, para no unir datos que no seran utilizados, en primera instancia filtraremos el dataset de productos para quedarnos unicamente con los lacteos.

In [9]:
```
list[productos.categoria.unique()]
```

Out[9]:
```
list[array(['Aceite', 'Aceite de oliva', 'Aderezos', 'Agua', 'Arroz',
       'Bebes y niños', 'Bebidas con alcohol', 'Bebidas sin alcohol',
       'Bebidas deportivas', 'Jugos en polvo', 'Cacao y café',
       'Carnes congeladas', 'Otros congelados', 'Conservas',
       'Endulzantes', 'Especias', 'Golosinas', 'Grasas', 'Harinas',
       'Infusiones', 'Lacteos', 'Leche', 'Leche en polvo', 'Limpieza',
       'Manteca', 'Mascotas', 'Mermeladas y dulces',
       'Cereales azucarados', 'Panificados', nan, 'Pastas', 'Perfumeria',
       'Postres y reposteria', 'Premezclas', 'Quesos', 'Salsas', 'Sopas',
       'Verduras congeladas', 'Yogur'], dtype=object)]
```

Vemos las categorias que tiene nuestro dataset, ya que para el analisis buscabamos analizar los productos de la canasta basica. Al visualizar las diferentes categorias se observa que una de ellas pertenece a NANS. Antes de filtrar el dataset analizaremos estso NANS para ver si son relevantes para el trabajo.

In [10]:
```
productos[productos.categoria.isna()]
```

Out[10]:

	_id/$oid	nombre	categoria	marca	presentacion	id
706	5cbc69be7af152186c0cd637	Mix de Frutos Secos y Semillas Nutritivo Natur...	NaN	ARCOR	27.0 gr	7790580110413
994	5cbc69be7af152186c0cd868	Crema de Avellana con Cacao Nutella 140 Gr	NaN	NUTELLA	140.0 gr	7898024395232

Como este producto no son parte de la canasta basica, no es relevante que falte su categoria, ya que no vamos a utilizarlo para el analisis. Podemos ignorarlo o eliminarlo. Optaremos por eliminarlo.

In [11]:
```
productos = productos.dropna(subset = "categoria")
productos.isna().sum()
```

Out[11]:
```
_id/$oid        0
nombre          0
categoria       0
marca           0
presentacion    0
id              0
dtype: int64
```

Una vez eliminados, filtraremos por las categorias pertenecientes a la canasta basica.

In [12]:
```
canasta_basica = ["Agua", "Leche" , "Arroz", "Harinas", "Pastas"]

productos = productos[(productos.categoria.isin(canasta_basica))]
productos.head()
```

Out[12]:

	_id/$oid	nombre	categoria	marca	presentacion	id
32	5cbc69be7af152186c0cd83c	Agua Mineral con Gas Villavicencio 1.5 Lt	Agua	VILLAVICENCIO	1.5 lt	7798062547788
33	5cbc69be7af152186c0cd5f5	Agua Mineral sin Gas Bajo Sodio Ser 1.5 Lt	Agua	SER	1.5 lt	7790315058706
34	5cbc69be7af152186c0cd692	Agua Mineral sin Gas Bonaqua 1.5 Lt	Agua	BONAQUA	1.5 lt	7790895003875
35	5cbc69be7af152186c0cd691	Agua Mineral sin Gas Bonaqua 500 Cc	Agua	BONAQUA	500.0 cc	7790895003868
36	5cbc69be7af152186c0cd7a7	Agua Mineral sin Gas Eco de Los Andes 500 Cc	Agua	ECO DE LOS ANDES	500.0 cc	7792799000011

Verificamos que las categorias en el nuevo df sean las seleccionadas

In [13]:
```
list[productos.categoria.unique()]
```

Out[13]:
```
list[array(['Agua', 'Arroz', 'Harinas', 'Leche', 'Pastas'], dtype=object)]
```

Ahora si uno los dataframes.

In [14]:
```
precios_claros = pd.merge(productos, precios, how = "left", left_on= 'id', right_on= 'producto_id')\
    .merge(sucursales, how = "left", left_on = 'sucursal_id', right_on = 'id')

precios_claros
```

Out[14]:

	_id/$oid	nombre	categoria	marca	presentacion	id	precio	sucursal_id	comerci
0	5cbc69be7af152186c0cd83c	Agua Mineral con Gas Villavicencio 1.5 Lt	Agua	VILLAVICENCIO	1.5 lt	7798062547788	70.00	10-1-112	1
1	5cbc69be7af152186c0cd83c	Agua Mineral con Gas Villavicencio 1.5 Lt	Agua	VILLAVICENCIO	1.5 lt	7798062547788	85.00	10-1-142	1
2	5cbc69be7af152186c0cd83c	Agua Mineral con Gas Villavicencio 1.5 Lt	Agua	VILLAVICENCIO	1.5 lt	7798062547788	69.00	10-1-178	1
3	5cbc69be7af152186c0cd83c	Agua Mineral con Gas Villavicencio 1.5 Lt	Agua	VILLAVICENCIO	1.5 lt	7798062547788	75.50	10-1-233	1
4	5cbc69be7af152186c0cd83c	Agua Mineral con Gas Villavicencio 1.5 Lt	Agua	VILLAVICENCIO	1.5 lt	7798062547788	73.00	10-1-29	1
...	...	...	...	...	...	...	...	...	
14242	5cbc69be7af152186c0cd585	Risotto 4 Quesos Gallo 200 Gr	Arroz	GALLO	200.0 gr	7790070411754	139.00	49-1-2	4
14243	5cbc69be7af152186c0cd585	Risotto 4 Quesos Gallo 200 Gr	Arroz	GALLO	200.0 gr	7790070411754	110.90	5-1-3	
14244	5cbc69be7af152186c0cd585	Risotto 4 Quesos Gallo 200 Gr	Arroz	GALLO	200.0 gr	7790070411754	139.00	50-1-2	5
14245	5cbc69be7af152186c0cd585	Risotto 4 Quesos Gallo 200 Gr	Arroz	GALLO	200.0 gr	7790070411754	123.55	6-1-26	
14246	5cbc69be7af152186c0cd585	Risotto 4 Quesos Gallo 200 Gr	Arroz	GALLO	200.0 gr	7790070411754	123.55	6-2-1	

14247 rows × 19 columns

Antes de empezar el analisis, miramos que columnas tiene para ver con cuales quedarnos para el analisis.

In [15]:
```
precios_claros.columns
```

Out[15]:
```
Index(['_id/$oid', 'nombre', 'categoria', 'marca', 'presentacion', 'id',
       'precio', 'sucursal_id', 'comercioId', 'banderaId',
       'banderaDescripcion', 'comercioRazonSocial', 'provincia', 'localidad',
       'direccion', 'lat', 'lng', 'sucursalNombre', 'sucursalTipo'],
      dtype='object')
```

Seleccionamos las columnas con las que vamos a trabajar.

In [16]:
```
precios_claros = precios_claros[["id", "categoria", "marca", "presentacion", "precio", 'sucursal_id' ,"sucursal
precios_claros
```

Out[16]:

	id	categoria	marca	presentacion	precio	sucursal_id	sucursalTipo	banderaDescripcion
0	7798062547788	Agua	VILLAVICENCIO	1.5 lt	70.00	10-1-112	Hipermercado	Hipermercado Carrefour
1	7798062547788	Agua	VILLAVICENCIO	1.5 lt	85.00	10-1-142	Supermercado	Hipermercado Carrefour
2	7798062547788	Agua	VILLAVICENCIO	1.5 lt	69.00	10-1-178	Supermercado	Hipermercado Carrefour
3	7798062547788	Agua	VILLAVICENCIO	1.5 lt	75.50	10-1-233	Hipermercado	Hipermercado Carrefour
4	7798062547788	Agua	VILLAVICENCIO	1.5 lt	73.00	10-1-29	Hipermercado	Hipermercado Carrefour
...	...	...	...	...	...	...	...	...
14242	7790070411754	Arroz	GALLO	200.0 gr	139.00	49-1-2	Supermercado	Super Tuti1 y Super Tuti 3
14243	7790070411754	Arroz	GALLO	200.0 gr	110.90	5-1-3	Hipermercado	California Supermercados
14244	7790070411754	Arroz	GALLO	200.0 gr	139.00	50-1-2	Supermercado	Super Tuti2 y Super Todo
14245	7790070411754	Arroz	GALLO	200.0 gr	123.55	6-1-26	Supermercado	Supermercados Comodin
14246	7790070411754	Arroz	GALLO	200.0 gr	123.55	6-2-1	Hipermercado	Maxi Comodin

14247 rows × 8 columns

Como el objetivo del trabajo es poder predecir a que tipo de cadena pertenece el producto y en nuestro dataset actual hay demasiadas cadenas, filtraremos el dataset por algunas cadenas de comercios, las que se cosideran mas relevantes e influyentes en el mercado. !!!Como considero cada cadena

In [17]:
```
cadenas = ["Disco", "Hipermercado Carrefour", "Supermercados DIA"]
precios_claros = precios_claros[precios_claros.banderaDescripcion.isin(cadenas)]
precios_claros
```

Out[17]:

	id	categoria	marca	presentacion	precio	sucursal_id	sucursalTipo	banderaDescripcion
0	7798062547788	Agua	VILLAVICENCIO	1.5 lt	70.00	10-1-112	Hipermercado	Hipermercado Carrefour
1	7798062547788	Agua	VILLAVICENCIO	1.5 lt	85.00	10-1-142	Supermercado	Hipermercado Carrefour
2	7798062547788	Agua	VILLAVICENCIO	1.5 lt	69.00	10-1-178	Supermercado	Hipermercado Carrefour
3	7798062547788	Agua	VILLAVICENCIO	1.5 lt	75.50	10-1-233	Hipermercado	Hipermercado Carrefour
4	7798062547788	Agua	VILLAVICENCIO	1.5 lt	73.00	10-1-29	Hipermercado	Hipermercado Carrefour
...	...	...	...	...	...	...	...	...
14172	7790236001263	Pastas	LA SALTEÑA	400.0 gr	79.99	15-1-1059	Supermercado	Supermercados DIA
14173	7790236001263	Pastas	LA SALTEÑA	400.0 gr	75.00	15-1-800	Autoservicio	Supermercados DIA
14199	7790236001263	Pastas	LA SALTEÑA	400.0 gr	77.00	9-2-4	Supermercado	Disco
14200	7790236001263	Pastas	LA SALTEÑA	400.0 gr	75.00	9-2-583	Supermercado	Disco
14203	7790070411754	Arroz	GALLO	200.0 gr	136.00	10-1-49	Hipermercado	Hipermercado Carrefour

2486 rows × 8 columns

Establecemos mejores nombres a nuestras columnas, en base a los cuales se realizara el listado de variables del trabajo.

In [18]:
```
precios_claros = precios_claros.rename(columns = { 'id' : 'producto_id', "sucursalTipo" : "tipo_cadena", 'bande
```

Como para el analisis necesitamos la presentacion del producto separada de la unidad de medida, primero separaremos la columna para realizar un ultimo filtrado previo al preprocesamiento de los datos.

In [19]:
```
precios_claros[['presentacion', 'unidad_presentacion']] = precios_claros['presentacion'].str.split(' ',expand=T
```

Cambiamos la variable a tipo numerico y verificamos que se haya cambiado efectivamente

In [20]:
```
precios_claros["presentacion"] = pd.to_numeric(precios_claros.presentacion)
precios_claros.dtypes
```

Out[20]:
```
producto_id             object
categoria               object
marca                   object
presentacion           float64
precio                 float64
sucursal_id             object
tipo_cadena             object
cadena                  object
unidad_presentacion     object
dtype: object
```

2 - PREPROCESAMIENTO

Veo las columnas que hay

In [21]:
```
precios_claros.columns
```

Out[21]:
```
Index(['producto_id', 'categoria', 'marca', 'presentacion', 'precio',
       'sucursal_id', 'tipo_cadena', 'cadena', 'unidad_presentacion'],
      dtype='object')
```

Las dimensiones:

In [22]:
```
dimensiones = precios_claros.shape
print(f'El dataset cuenta con {dimensiones[0]} resgistros y {dimensiones[1]} columnas')
```

```
El dataset cuenta con 2486 resgistros y 9 columnas
```

Miramos la tipologia de los datos de las variables. De igual manera seran tratados mas adelante.

In [23]:
```
precios_claros.dtypes
```

Out[23]:
```
producto_id             object
categoria               object
marca                   object
presentacion           float64
precio                 float64
sucursal_id             object
tipo_cadena             object
cadena                  object
unidad_presentacion     object
dtype: object
```

- Duplicados

Miramos cuantos duplicados tiene el dataset y los miramos para ver si hay que eliminarlos para evitar el overfitting.

In [24]:
```
print(f"El dataset parece tener {len(precios_claros) - len(precios_claros[precios_claros.duplicated()])} filas
```

```
El dataset parece tener 1731 filas duplicadas
```

Cuando miramos esos datos vemos que en realidad no son duplicados, es decir, las primeras columnas contienen el mismo dato porque hacen referencia al mismo producto, pero en realidad hace referencia a ese producto en distintas sucursales con distintos precios. Dado esto, no vamos a eliminarlos porque es precisamente ese el objetivo de analisis en este trabajo, mirar los productos y sus precios comparandolos en distintas cadenas y tipos de cadena.

In [25]:
```
 precios_claros[precios_claros.duplicated()]
```

Out[25]:

	producto_id	categoria	marca	presentacion	precio	sucursal_id	tipo_cadena	cadena	unidad_presentaci
68	7798062547788	Agua	VILLAVICENCIO	1.5	70.0	10-1-112	Hipermercado	Hipermercado Carrefour	
70	7798062547788	Agua	VILLAVICENCIO	1.5	85.0	10-1-142	Supermercado	Hipermercado Carrefour	
73	7798062547788	Agua	VILLAVICENCIO	1.5	73.0	10-1-29	Hipermercado	Hipermercado Carrefour	
75	7798062547788	Agua	VILLAVICENCIO	1.5	88.0	10-1-48	Hipermercado	Hipermercado Carrefour	
76	7798062547788	Agua	VILLAVICENCIO	1.5	83.0	10-1-53	Hipermercado	Hipermercado Carrefour	
...	...	...	...	...	...	...	...	...	
14076	7790236001263	Pastas	LA SALTEÑA	400.0	72.0	10-1-48	Hipermercado	Hipermercado Carrefour	
14107	7790236001263	Pastas	LA SALTEÑA	400.0	75.0	15-1-1803	Supermercado	Supermercados DIA	
14136	7790236001263	Pastas	LA SALTEÑA	400.0	69.0	10-1-142	Supermercado	Hipermercado Carrefour	
14137	7790236001263	Pastas	LA SALTEÑA	400.0	85.0	10-1-147	Hipermercado	Hipermercado Carrefour	
14143	7790236001263	Pastas	LA SALTEÑA	400.0	72.0	10-1-48	Hipermercado	Hipermercado Carrefour	

755 rows × 9 columns

Igualmente podemos analizar que productos con su respectiva sucursal tienen repetidos los precios. Esto se da debido a que se tomaron los precios 3 veces en el mes. Como sacar el promedio podria ser alejado a la realidad por la existencia de outliers, nos quedaremos con el primer precio tomado de cada producto en el mes.

In [26]:
```
precios_claros.drop_duplicates(subset = ['producto_id', 'sucursal_id'], keep = "first", inplace = True)
```

In [27]:
```
sin_duplicados = len(precios_claros)
print(f"La cantidad de registros sin duplicados es de {sin_duplicados}")
```

```
La cantidad de registros sin duplicados es de 1729
```

In [28]:
```
precios_claros.drop(columns = ['producto_id', 'sucursal_id'], inplace = True)
```

Verificamos su eliminacion

In [29]:
```
precios_claros.columns
```

Out[29]:
```
Index(['categoria', 'marca', 'presentacion', 'precio', 'tipo_cadena', 'cadena',
       'unidad_presentacion'],
      dtype='object')
```

- Faltantes

Porcentaje de faltantes de variables por columna. Nuestro dataset no contiene faltantes, por lo que no hay que hacer ningun tipo de tratamiento especial.

In [30]:
```
round(precios_claros.isnull().sum().sort_values(ascending=False)/len(precios_claros) * 100 ,3)
```

Out[30]:
```
categoria              0.0
marca                  0.0
presentacion           0.0
precio                 0.0
tipo_cadena            0.0
cadena                 0.0
unidad_presentacion    0.0
dtype: float64
```

- Outliers

Antes de poder empezar es fundamentar analizar la posible existencia de outliers en nuestros datos para poder tratarlos de manera adecuada.

In [31]:
```
precios_claros.precio.describe().round(2)
```

Out[31]:
```
count    1729.00
mean       84.51
std        45.02
min         9.59
25%        54.75
50%        71.00
75%        92.00
max       224.00
Name: precio, dtype: float64
```

Mediante el boxplot podemos observar que el cuadrado azul es donde hay mayor concentracion y es el rango intercuantil. Lo que esta fuera de los bigotes son los que parecen ser outliers o podrian ser malas imputaciones.

In [32]:
```
fig, ax = plt.subplots(1,2,figsize=(14,5))

ax[0].set_title(f"Boxplot de precio")
sns.boxplot(data = precios_claros, x = "precio",  ax = ax[0])

ax[1].set_title(f"Boxplot de presentacion")
sns.boxplot(data = precios_claros, x = "presentacion",  ax = ax[1])
```

Out[32]:
```
<AxesSubplot: title={'center': 'Boxplot de presentacion'}, xlabel='presentacion'>
```

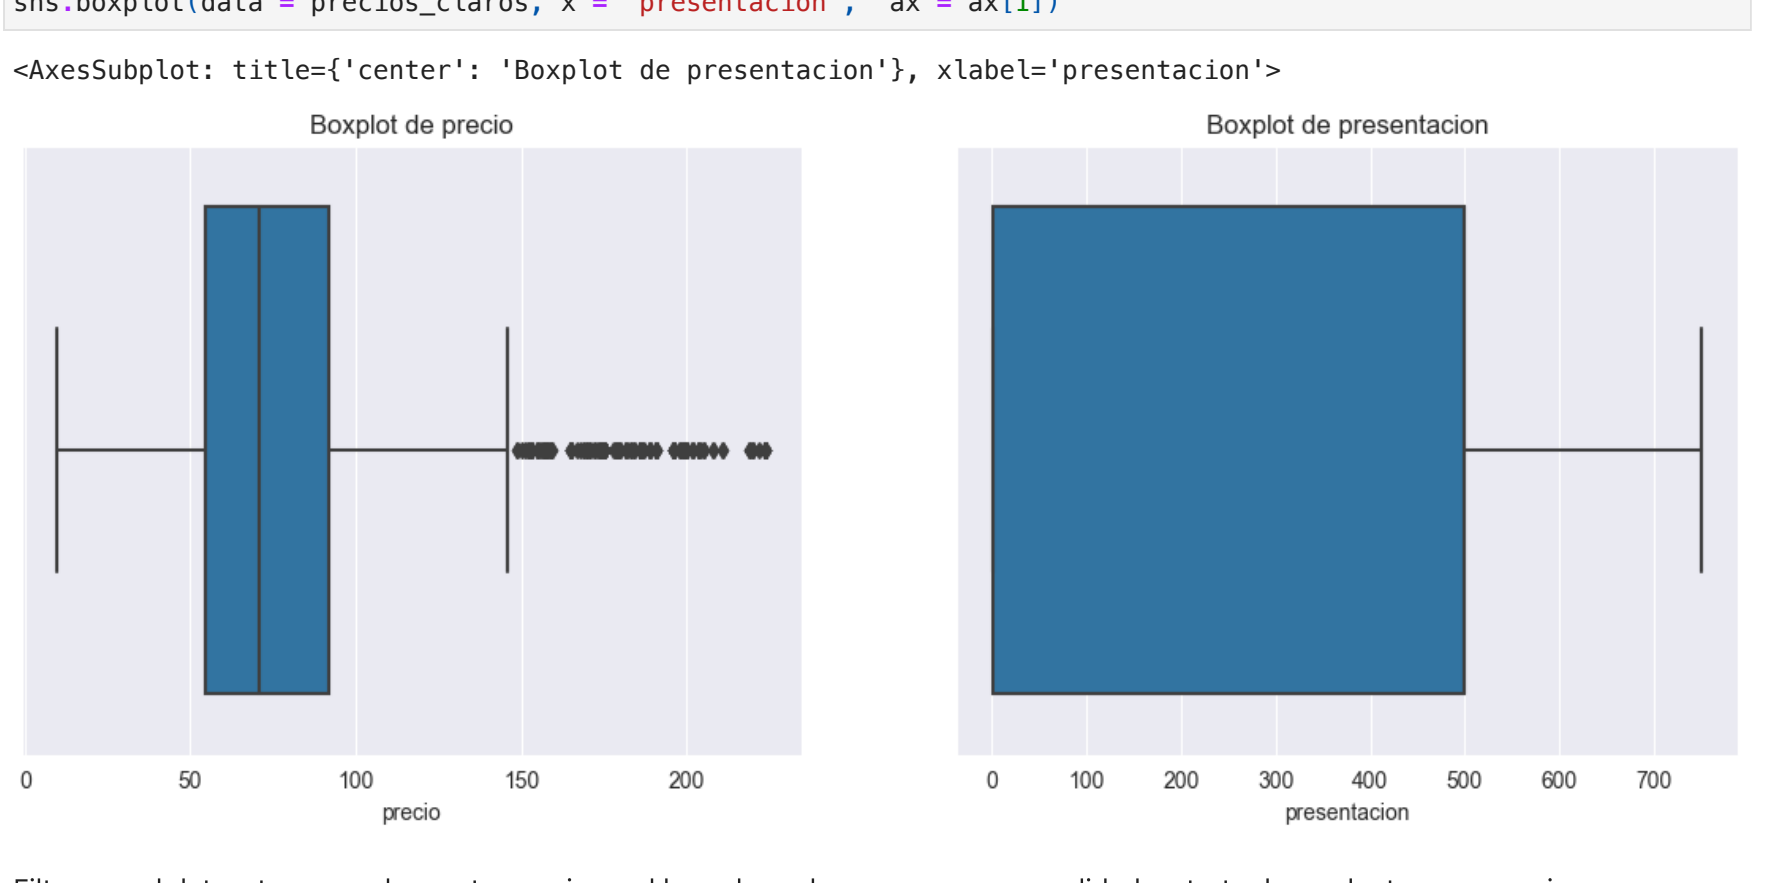

Filtramos el dataset para evaluar estos pecios y al hacerlo podemos ver que en realidad se trata de productos con precio mas elevado porque su presentacion tambien es mayor. Es por ello que tomaremos la decision de no eliminarlos.

In [33]:
```
precios_claros[precios_claros.precio >= 125].sort_values(ascending = True, by = ["presentacion", "precio"])
```

Out[33]:

	categoria	marca	presentacion	precio	tipo_cadena	cadena	unidad_presentacion
2944	Arroz	GALLO	1.0	134.0	Hipermercado	Hipermercado Carrefour	kg
2941	Arroz	GALLO	1.0	135.0	Hipermercado	Hipermercado Carrefour	kg
3061	Arroz	GALLO	1.0	135.0	Supermercado	Disco	kg
3071	Arroz	GALLO	1.0	135.0	Hipermercado	Hipermercado Carrefour	kg
2948	Arroz	GALLO	1.0	146.0	Hipermercado	Hipermercado Carrefour	kg
...	...	...	...	...	...	...	...
4165	Harinas	MAIZENA	520.0	139.0	Hipermercado	Hipermercado Carrefour	gr
4229	Harinas	MAIZENA	520.0	139.0	Supermercado	Hipermercado Carrefour	gr
4163	Harinas	MAIZENA	520.0	140.0	Hipermercado	Hipermercado Carrefour	gr
4166	Harinas	MAIZENA	520.0	143.0	Hipermercado	Hipermercado Carrefour	gr
4154	Harinas	MAIZENA	520.0	159.0	Supermercado	Disco	gr

300 rows × 7 columns

In [34]:
```
precios_claros.to_csv("data/clean_precios_claros.csv", index=False)
```

3 - ANALISIS INICIAL

Para comenzar haremos un analisis de los precios de los productos seleccionados.

In [35]:
```
precios_claros
```

Out[35]:

	categoria	marca	presentacion	precio	tipo_cadena	cadena	unidad_presentacion
0	Agua	VILLAVICENCIO	1.5	70.00	Hipermercado	Hipermercado Carrefour	lt
1	Agua	VILLAVICENCIO	1.5	85.00	Supermercado	Hipermercado Carrefour	lt
2	Agua	VILLAVICENCIO	1.5	69.00	Supermercado	Hipermercado Carrefour	lt
3	Agua	VILLAVICENCIO	1.5	75.50	Hipermercado	Hipermercado Carrefour	lt
4	Agua	VILLAVICENCIO	1.5	73.00	Hipermercado	Hipermercado Carrefour	lt
...	...	...	...	...	...	...	...
14172	Pastas	LA SALTEÑA	400.0	79.99	Supermercado	Supermercados DIA	gr
14173	Pastas	LA SALTEÑA	400.0	75.00	Autoservicio	Supermercados DIA	gr
14199	Pastas	LA SALTEÑA	400.0	77.00	Supermercado	Disco	gr
14200	Pastas	LA SALTEÑA	400.0	75.00	Supermercado	Disco	gr
14203	Arroz	GALLO	200.0	136.00	Hipermercado	Hipermercado Carrefour	gr

1729 rows × 7 columns

In [36]:
```
print("Cantidad de registros por cadena:")
precios_claros.cadena.value_counts()
```

```
Cantidad de registros por cadena:
```

Out[36]:
```
Hipermercado Carrefour    1267
Disco                      243
Supermercados DIA          219
Name: cadena, dtype: int64
```

In [37]:
```
dia = precios_claros[precios_claros.cadena == "Supermercados DIA"]
disco = precios_claros[precios_claros.cadena == "Disco"]
carrefour = precios_claros[precios_claros.cadena == "Hipermercado Carrefour"]
```

In [38]:
```
print(f"La marca con mayor cantidad de registros en dia es {dia.marca.mode()[0]}, en carrefour tambien es {carr
```

```
La marca con mayor cantidad de registros en dia es LUCCHETTI, en carrefour tambien es LUCCHETTI y en disco es M
ATARAZZO.
```

In [39]:
```
print(f"En dia hay mayor cantidad de productos pertenecientes a la categoria {dia.categoria.mode()[0]}, en carr
```

```
En dia hay mayor cantidad de productos pertenecientes a la categoria Agua, en carrefour a Pastas y en disco tam
bien a Pastas.
```

In [40]:
```
print(f"Los productos en dia en su mayoria pertenecen al tipo de cadena {dia.tipo_cadena.mode()[0]}, en carrefo
```

```
Los productos en dia en su mayoria pertenecen al tipo de cadena Supermercado, en carrefour a Hipermercado y en
disco tambien a Supermercado.
```

A continuacion se observa los precios promedio por cadena. Se puede ver que en la mayoria de categorias se cumple nuestra prediccion de que los precios son mas baratos en dia, seguidos de carrefour y ultimo por disco. Sin embargo, en la categoria agua dia es la cadena con promedio de precio mas elevado.

In [41]:
```
dia.groupby("categoria").precio.mean().round(2)
```

Out[41]:
```
categoria
Agua       83.42
Arroz      84.67
Harinas    71.89
Leche      42.46
Pastas     76.04
Name: precio, dtype: float64
```

In [42]:
```
carrefour.groupby("categoria").precio.mean().round(2)
```

Out[42]:
```
categoria
Agua       78.85
Arroz      94.69
Harinas    70.24
Leche      45.04
Pastas     93.63
Name: precio, dtype: float64
```

In [43]:
```
disco.groupby("categoria").precio.mean().round(2)
```

Out[43]:
```
categoria
Agua        80.03
Arroz      102.79
Harinas     75.07
Leche       58.88
Pastas      93.47
Name: precio, dtype: float64
```

In [44]:
```
import matplotlib.pyplot as plt
fig, axs = plt.subplots(1, 2, figsize=(14,5), constrained_layout = True)

por_categoria = (precios_claros.groupby('categoria').marca.nunique()).sort_values().reset_index()
por_cadena = (precios_claros.groupby('cadena').marca.nunique()).sort_values().reset_index()

axs[0].barh(por_categoria.categoria , por_categoria.marca, label= "marcas", color = "purple")
axs[0].set_title('Cantidad de marcas por categoria')
axs[0].legend()
# Second subplot
axs[1].barh(por_cadena.cadena, por_cadena.marca, label= "marcas", color = "green")
axs[1].set_title("Marcas por cadena")
axs[1].legend()
# Global figure methods
plt.suptitle('Distribcion de marcas')
print(f"Como se puede ver, Agua es la categoria con mayor cantidad de marcas, y carreforur la caadena con mayor
plt.show()
```

```
Como se puede ver, Agua es la categoria con mayor cantidad de marcas, y carreforur la caadena con mayor varieda
d de marcas de la canasta basica
```

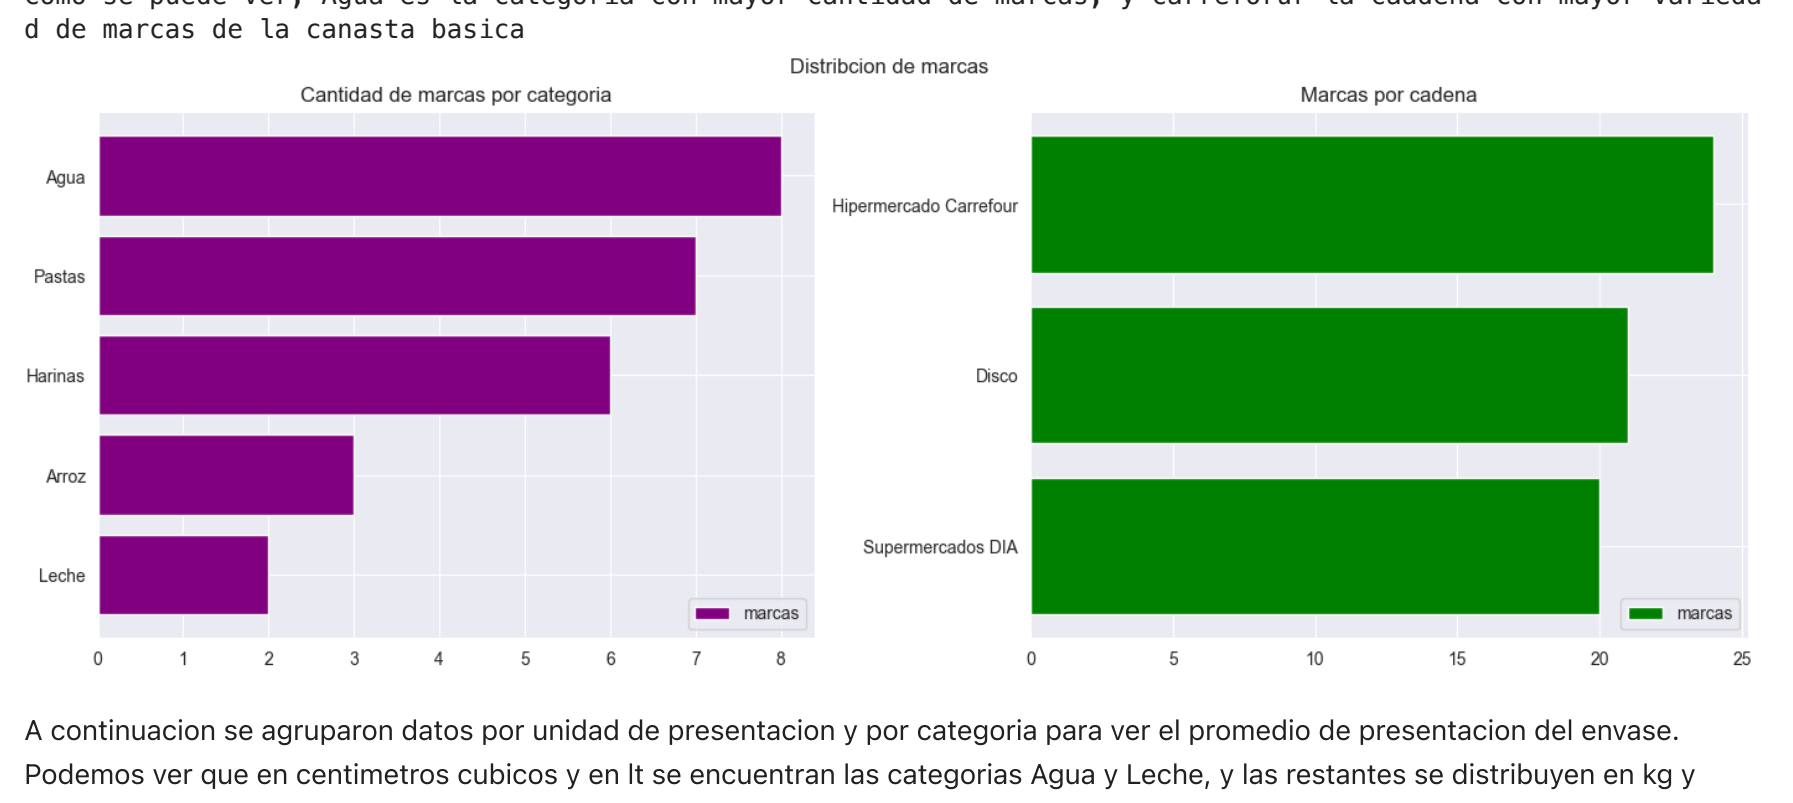

A continuacion se agruparon datos por unidad de presentacion y por categoria para ver el promedio de presentacion del envase. Podemos ver que en centimetros cubicos y en lt se encuentran las categorias Agua y Leche, y las restantes se distribuyen en kg y gr. Ademas se puede ver que los promedios en gr y en cc son mucho mayores a los que estan medidos en kg y lt, y esto se da porque estas dos utlimas son unidades de medida mayores que las dos anteriores.

In [45]:
```
precios_claros.groupby(["unidad_presentacion", "categoria"]).presentacion.mean().round(2)
```

Out[45]:
```
unidad_presentacion  categoria
cc                   Agua         500.00
                     Leche        200.00
gr                   Arroz        464.71
                     Harinas      495.58
                     Pastas       486.87
kg                   Arroz          1.00
                     Harinas        1.00
lt                   Agua           2.84
                     Leche          1.00
Name: presentacion, dtype: float64
```

In [46]:
```
import matplotlib.pyplot as plt
fig, axs = plt.subplots(1, 3, figsize=(14,3), constrained_layout = True)

dia_plt = dia.groupby("tipo_cadena").count().reset_index()
disco_plt = disco.groupby("tipo_cadena").count().reset_index()
carrefour_plt = carrefour.groupby("tipo_cadena").count().reset_index()

axs[0].bar(dia_plt.tipo_cadena , dia_plt.cadena, color = "black")
axs[0].set_title(f'Cantidad de tipo de cadena en Dia')
# Second subplot
axs[1].bar(carrefour_plt.tipo_cadena , carrefour_plt.cadena, color = "blue")
axs[1].set_title(f'Cantidad de tipo de cadena en Carrefour')

axs[2].bar(disco_plt.tipo_cadena , disco_plt.cadena, color = "red")
axs[2].set_title(f'Cantidad de tipo de cadena en Disco')
# Global figure methods
plt.suptitle('Distribcion de tipo de cadena por cadena de comercio')
plt.savefig("data/plot_tipo_cadena.png")
plt.show()
print(f"Se puede ver que Supermerados dia tiene autoservicios y en su mayoria supermercados, Carrefour en su ma
```

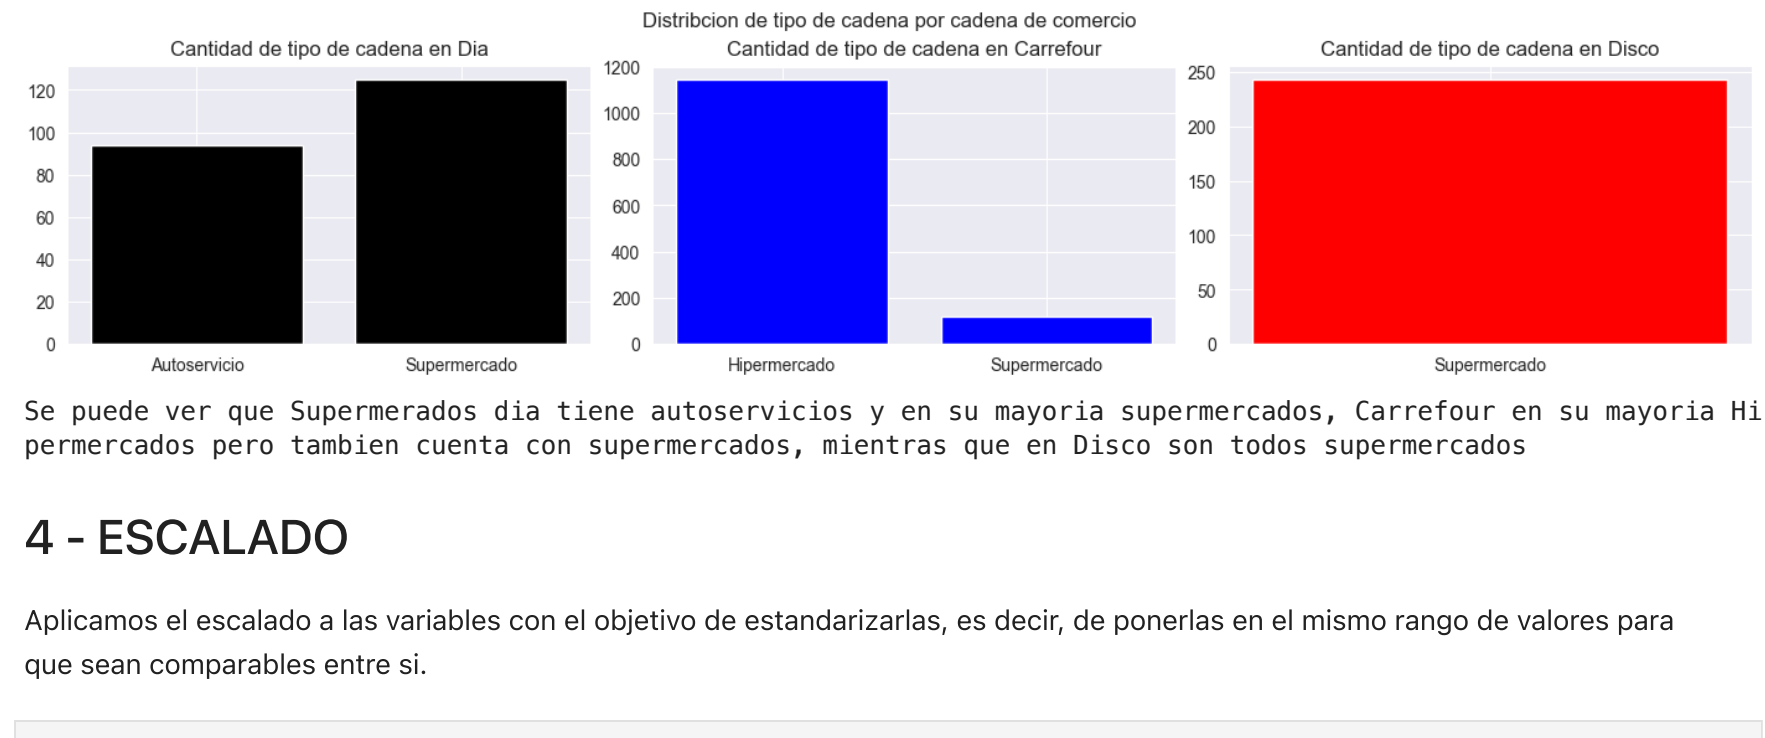

Se puede ver que Supermerados dia tiene autoservicios y en su mayoria supermercados, Carrefour en su mayoria Hipermercados pero tambien cuenta con supermercados, mientras que en Disco son todos supermercados

4 - ESCALADO

Aplicamos el escalado a las variables con el objetivo de estandarizarlas, es decir, de ponerlas en el mismo rango de valores para que sean comparables entre si.

In [47]:
```
precios_claros.dtypes
```

Out[47]:
```
categoria              object
marca                  object
presentacion          float64
precio                float64
tipo_cadena            object
cadena                 object
unidad_presentacion    object
dtype: object
```

In [48]:
```
numericas = precios_claros.select_dtypes(exclude=['object']).columns

print("Hacer un escalado a la variables: ")
for variable in numericas:
    print(f"\t- {variable}")
```

```
Hacer un escalado a la variables:
        - presentacion
        - precio
```

Variable `presentacion`

Como se ve en los graficos, esta variable no tiene una distribucion normaly esto se da porque los productos estan en diferentes unidades de medida. Por ello, previo a escalar la variable, podemos pasar los cc a lt y los gr a kg.

In [49]:
```
variable = 'presentacion'

fig, ax = plt.subplots(1,2,figsize=(14,5))

ax[0].set_title(f"Distribucion de {variable}")
sns.histplot(data = precios_claros, x = f"{variable}", kde=True, ax = ax[0])

ax[1].set_title(f"Boxplot de{variable}")

sns.boxplot(data = precios_claros, x = f"{variable}", ax=ax[1])
```

Out[49]: <AxesSubplot: title={'center': 'Boxplot depresentacion'}, xlabel='presentacion'>

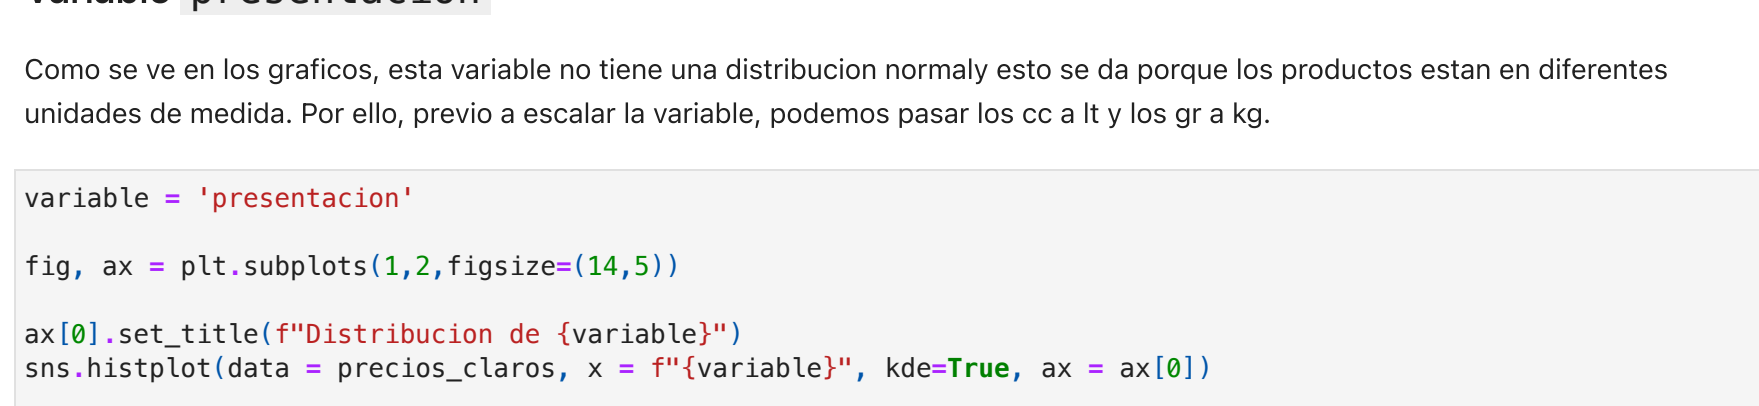

In [50]:
```
precios_claros.presentacion.describe().round(2)
```

Out[50]:
```
count    1729.00
mean      310.05
std       238.63
min         1.00
25%         1.50
50%       500.00
75%       500.00
max       750.00
Name: presentacion, dtype: float64
```

Como 1 litro equivale a 1000 centimetros cubicos y 1 kilo gramo equivale a 1000 gramos, dividimos la presentacion de aquellos productos que esten medidos en cc y gr por 1000 y cambiamos su unidad de medida.

In [51]:
```
precios_claros.loc[precios_claros['unidad_presentacion'] == "cc", 'presentacion'] = precios_claros.presentacion
precios_claros['unidad_presentacion'] = precios_claros['unidad_presentacion'].str.replace("cc", "lt", regex = F
```

In [52]:
```
precios_claros.loc[precios_claros['unidad_presentacion'] == "gr", 'presentacion'] = precios_claros.presentacion
precios_claros['unidad_presentacion'] = precios_claros['unidad_presentacion'].str.replace("gr", "kg", regex = F
```

Vemos que ahora las unicas unidades de medida son litros y kg.

In [53]:
```
precios_claros.unidad_presentacion.value_counts(dropna = False)
```

Out[53]:
```
kg    1203
lt     526
Name: unidad_presentacion, dtype: int64
```

In [54]:
```
variable = 'presentacion'

fig, ax = plt.subplots(1,2,figsize=(14,5))

ax[0].set_title(f"Distribucion de {variable}")
sns.histplot(data = precios_claros, x = f"{variable}", kde=True, ax = ax[0])

ax[1].set_title(f"Boxplot de{variable}")

sns.boxplot(data = precios_claros, x = f"{variable}", ax=ax[1])
```

Out[54]: <AxesSubplot: title={'center': 'Boxplot depresentacion'}, xlabel='presentacion'>

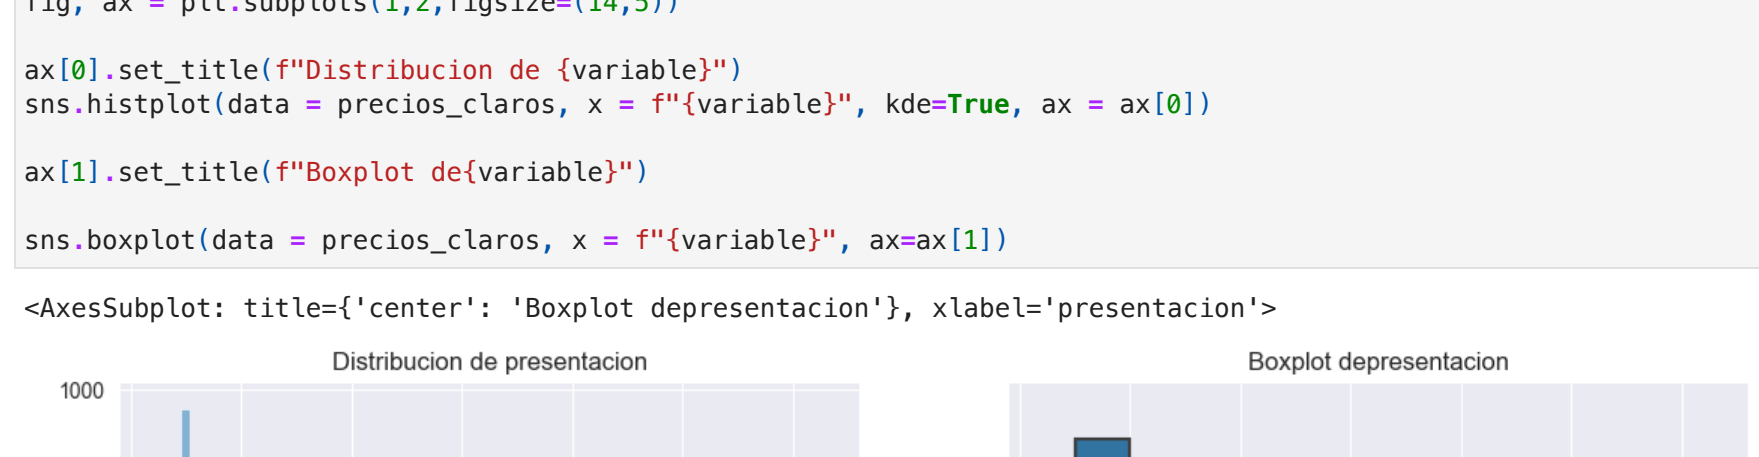

En esta instancia se puede ver nuevamente que los que parece ser malas imputaciones es porque el producto es de mayor presentacion.

In [55]:
```
precios_claros[precios_claros.presentacion > 3]
```

Out[55]:

	categoria	marca	presentacion	precio	tipo_cadena	cadena	unidad_presentacion
880	Agua	KIN	6.00	125.00	Hipermercado	Hipermercado Carrefour	lt
886	Agua	KIN	6.00	121.49	Autoservicio	Supermercados DIA	lt
887	Agua	KIN	6.00	123.39	Autoservicio	Supermercados DIA	lt
888	Agua	KIN	6.00	93.00	Supermercado	Supermercados DIA	lt
891	Agua	KIN	6.00	125.00	Supermercado	Disco	lt
...	...	...	...	...	...	...	...
1345	Agua	VILLA DEL SUR	6.25	175.00	Hipermercado	Hipermercado Carrefour	lt
1384	Agua	VILLA DEL SUR	6.25	197.99	Supermercado	Supermercados DIA	lt
1385	Agua	VILLA DEL SUR	6.25	198.99	Autoservicio	Supermercados DIA	lt
1386	Agua	VILLA DEL SUR	6.25	175.00	Autoservicio	Supermercados DIA	lt
1423	Agua	VILLA DEL SUR	6.25	187.00	Supermercado	Disco	lt

84 rows × 7 columns

Ahora si le podemos aplicar el escalador.

In [56]:
```
from sklearn.preprocessing import RobustScaler

escalador = RobustScaler()

variable = 'presentacion'

precios_claros[[variable]] = escalador.fit_transform(precios_claros[[variable]])

print(f"Como los datos en {variable} tienen outliers, imputamos el RobustScaler, que escala los valores restand

precios_claros.head()
```

```
Como los datos en presentacion tienen outliers, imputamos el RobustScaler, que escala los valores restandole la mediana y dividiendolo por el rango intercuartil
```

Out[56]:

	categoria	marca	presentacion	precio	tipo_cadena	cadena	unidad_presentacion
0	Agua	VILLAVICENCIO	2.0	70.0	Hipermercado	Hipermercado Carrefour	lt
1	Agua	VILLAVICENCIO	2.0	85.0	Supermercado	Hipermercado Carrefour	lt
2	Agua	VILLAVICENCIO	2.0	69.0	Supermercado	Hipermercado Carrefour	lt
3	Agua	VILLAVICENCIO	2.0	75.5	Hipermercado	Hipermercado Carrefour	lt
4	Agua	VILLAVICENCIO	2.0	73.0	Hipermercado	Hipermercado Carrefour	lt

Variable `precio`

Al igual que en el caso anterior, aplicaremos el robust scaler.

In [57]:
```
variable = 'precio'

fig, ax = plt.subplots(1,2,figsize=(14,5))

ax[0].set_title(f"Distribucion de {variable}")
sns.histplot(data = precios_claros, x = f"{variable}", kde=True, ax = ax[0])

ax[1].set_title(f"Boxplot de{variable}")

sns.boxplot(data = precios_claros, x = f"{variable}", ax=ax[1])
```

Out[57]: <AxesSubplot: title={'center': 'Boxplot deprecio'}, xlabel='precio'>

In [58]:
```
from sklearn.preprocessing import RobustScaler

escalador = RobustScaler()

variable = 'precio'

precios_claros[[variable]] = escalador.fit_transform(precios_claros[[variable]])

print(f"Como los datos en {variable} tienen outliers, imputamos el RobustScaler, que escala los valores restand

precios_claros.head()
```

```
Como los datos en precio tienen outliers, imputamos el RobustScaler, que escala los valores restandole la mediana y dividiendolo por el rango intercuartil
```

Out[58]:

	categoria	marca	presentacion	precio	tipo_cadena	cadena	unidad_presentacion
0	Agua	VILLAVICENCIO	2.0	-0.026846	Hipermercado	Hipermercado Carrefour	lt
1	Agua	VILLAVICENCIO	2.0	0.375839	Supermercado	Hipermercado Carrefour	lt
2	Agua	VILLAVICENCIO	2.0	-0.053691	Supermercado	Hipermercado Carrefour	lt
3	Agua	VILLAVICENCIO	2.0	0.120805	Hipermercado	Hipermercado Carrefour	lt
4	Agua	VILLAVICENCIO	2.0	0.053691	Hipermercado	Hipermercado Carrefour	lt

5 - ENCODING

In [59]:
```
categoricas = precios_claros.select_dtypes(exclude=['float', 'integer']).columns
print("Hacer un encoding a la variables: ")
for variable in categoricas:
    print(f"\t- {variable}")
```

```
Hacer un encoding a la variables:
        - categoria
        - marca
        - tipo_cadena
        - cadena
        - unidad_presentacion
```

Variable `categoria`

Lo que hace este bloque de codigo expandir la columna inicial a columnas binarias para cada categoria adentro de la variable, asignandoles 1 y 0 dependiendo de si el producto cuenta con la categoria o no. Mediante este codigo pudimos automatizar la busqueda de las diferentes categorias y la asignacion del nombre de la columna. Se repite el codigo para todas las variables categoricas menos al target.

In [60]:
```
categorias = precios_claros.categoria.unique()
print("Categorias unicas: ")
for categoria in categorias:
    print(f"\t- {categoria}")
```

```
Categorias unicas:
        - Agua
        - Arroz
        - Harinas
        - Leche
        - Pastas
```

In [61]:
```
from sklearn.preprocessing import OneHotEncoder

ohe = OneHotEncoder(sparse=False)

df = precios_claros
variable = 'categoria'

ohe.fit(df[[variable]])

display(ohe.categories_)

display(ohe.get_feature_names_out())

variable_encoded = ohe.transform(df[[variable]])

df[ohe.get_feature_names_out()] = variable_encoded

df.drop(columns = variable, inplace = True)

print(f"Como {variable} es una variable multicategorica, creo una columna binaria para cada categoria")

df.head()
```

```
[array(['Agua', 'Arroz', 'Harinas', 'Leche', 'Pastas'], dtype=object)]
array(['categoria_Agua', 'categoria_Arroz', 'categoria_Harinas',
       'categoria_Leche', 'categoria_Pastas'], dtype=object)
Como categoria es una variable multicategorica, creo una columna binaria para cada categoria
```

Out[61]:

	marca	presentacion	precio	tipo_cadena	cadena	unidad_presentacion	categoria_Agua	categoria_Arroz
0	VILLAVICENCIO	2.0	-0.026846	Hipermercado	Hipermercado Carrefour	lt	1.0	0.0
1	VILLAVICENCIO	2.0	0.375839	Supermercado	Hipermercado Carrefour	lt	1.0	0.0
2	VILLAVICENCIO	2.0	-0.053691	Supermercado	Hipermercado Carrefour	lt	1.0	0.0
3	VILLAVICENCIO	2.0	0.120805	Hipermercado	Hipermercado Carrefour	lt	1.0	0.0
4	VILLAVICENCIO	2.0	0.053691	Hipermercado	Hipermercado Carrefour	lt	1.0	0.0

Variable `marca`

In [62]:
```
marcas = precios_claros.marca.unique()
print("Marcas unicas: ")
for marca in marcas:
    print(f"\t- {marca}")
```

```
Marcas unicas:
        - VILLAVICENCIO
        - SER
        - BONAQUA
        - ECO DE LOS ANDES
        - KIN
        - NESTLÉ
        - VILLA DEL SUR
        - GLACIAR
        - GALLO
        - MOLINOS ALA
        - LUCCHETTI
        - MAIZENA
        - PUREZA
        - CAÑUELAS
        - FAVORITA
        - QUAKER
        - ARCOR
        - LA SERENÍSIMA
        - ARMONÍA
        - GIACOMO
        - DON VICENTE
        - MATARAZZO
        - KNORR
        - LA SALTEÑA
```

In [63]:
```
from sklearn.preprocessing import OneHotEncoder

ohe = OneHotEncoder(sparse=False)

df = precios_claros
variable = 'marca'

ohe.fit(df[[variable]])

display(ohe.categories_)

display(ohe.get_feature_names_out())

variable_encoded = ohe.transform(df[[variable]])

df[ohe.get_feature_names_out()] = variable_encoded

df.drop(columns = variable, inplace = True)

print(f"Como {variable} es una variable multicategorica, creo una columna binaria para cada categoria")

df.head()
```

```
[array(['ARCOR', 'ARMONÍA', 'BONAQUA', 'CAÑUELAS', 'DON VICENTE',
       'ECO DE LOS ANDES', 'FAVORITA', 'GALLO', 'GIACOMO', 'GLACIAR',
       'KIN', 'KNORR', 'LA SALTEÑA', 'LA SERENÍSIMA', 'LUCCHETTI',
       'MAIZENA', 'MATARAZZO', 'MOLINOS ALA', 'NESTLÉ', 'PUREZA',
       'QUAKER', 'SER', 'VILLA DEL SUR', 'VILLAVICENCIO'], dtype=object)]
array(['marca_ARCOR', 'marca_ARMONÍA', 'marca_BONAQUA', 'marca_CAÑUELAS',
       'marca_DON VICENTE', 'marca_ECO DE LOS ANDES', 'marca_FAVORITA',
       'marca_GALLO', 'marca_GIACOMO', 'marca_GLACIAR', 'marca_KIN',
       'marca_KNORR', 'marca_LA SALTEÑA', 'marca_LA SERENÍSIMA',
       'marca_LUCCHETTI', 'marca_MAIZENA', 'marca_MATARAZZO',
       'marca_MOLINOS ALA', 'marca_NESTLÉ', 'marca_PUREZA',
       'marca_QUAKER', 'marca_SER', 'marca_VILLA DEL SUR',
       'marca_VILLAVICENCIO'], dtype=object)
Como marca es una variable multicategorica, creo una columna binaria para cada categoria
```

Out[63]:

	presentacion	precio	tipo_cadena	cadena	unidad_presentacion	categoria_Agua	categoria_Arroz	categoria_Harinas
0	2.0	-0.026846	Hipermercado	Hipermercado Carrefour	lt	1.0	0.0	0.0
1	2.0	0.375839	Supermercado	Hipermercado Carrefour	lt	1.0	0.0	0.0
2	2.0	-0.053691	Supermercado	Hipermercado Carrefour	lt	1.0	0.0	0.0
3	2.0	0.120805	Hipermercado	Hipermercado Carrefour	lt	1.0	0.0	0.0
4	2.0	0.053691	Hipermercado	Hipermercado Carrefour	lt	1.0	0.0	0.0

5 rows × 34 columns

Variable `tipo_cadena`

In [64]:
```
tipos_cadenas = precios_claros.tipo_cadena.unique()
print("Tipos de cadena unicas: ")
for tipo_cadena in tipos_cadenas:
    print(f"\t- {tipo_cadena}")
```

```
Tipos de cadena unicas:
        - Hipermercado
        - Supermercado
        - Autoservicio
```

In [65]:
```
from sklearn.preprocessing import OneHotEncoder

ohe = OneHotEncoder(sparse=False)

df = precios_claros
variable = 'tipo_cadena'

ohe.fit(df[[variable]])

display(ohe.categories_)

display(ohe.get_feature_names_out())

variable_encoded = ohe.transform(df[[variable]])

df[ohe.get_feature_names_out()] = variable_encoded

df.drop(columns = variable, inplace = True)

print(f"Como {variable} es una variable multicategorica, creo una columna binaria para cada categoria")

df.head()
```

```
[array(['Autoservicio', 'Hipermercado', 'Supermercado'], dtype=object)]
array(['tipo_cadena_Autoservicio', 'tipo_cadena_Hipermercado',
       'tipo_cadena_Supermercado'], dtype=object)
Como tipo_cadena es una variable multicategorica, creo una columna binaria para cada categoria
```

Out[65]:

	presentacion	precio	cadena	unidad_presentacion	categoria_Agua	categoria_Arroz	categoria_Harinas	categoria_Leche
0	2.0	-0.026846	Hipermercado Carrefour	lt	1.0	0.0	0.0	0.0
1	2.0	0.375839	Hipermercado Carrefour	lt	1.0	0.0	0.0	0.0
2	2.0	-0.053691	Hipermercado Carrefour	lt	1.0	0.0	0.0	0.0
3	2.0	0.120805	Hipermercado Carrefour	lt	1.0	0.0	0.0	0.0
4	2.0	0.053691	Hipermercado Carrefour	lt	1.0	0.0	0.0	0.0

5 rows × 36 columns

Variable `unidad_presentacion`

En este caso, como la variable ya es binaria, no es necesari expandirla, podemos hacer el encoding en la misma columna, asignandole 0 a los lt y 1 a los kg.

In [66]:
```
unidades_presentacion = precios_claros.unidad_presentacion.unique()
print("Unidades de presentacion unicas: ")
for unidad_presentacion in unidades_presentacion:
    print(f"\t- {unidad_presentacion}")
```

```
Unidades de presentacion unicas:
        - lt
        - kg
```

In [67]:
```
hot_encoder = OneHotEncoder(sparse = False, drop = 'if_binary', categories=[['lt', 'kg']]) #lt va a ser cero y

df = precios_claros
variable = 'unidad_presentacion'

df[variable] = hot_encoder.fit_transform(df[[variable]])

print("Como tengo una columna con dos categorias, hago el one-hot pero tranformando la columna en binaria")

df.head()
```

```
Como tengo una columna con dos categorias, hago el one-hot pero tranformando la columna en binaria
```

Out[67]:

	presentacion	precio	cadena	unidad_presentacion	categoria_Agua	categoria_Arroz	categoria_Harinas	categoria_Leche
0	2.0	-0.026846	Hipermercado Carrefour	0.0	1.0	0.0	0.0	0.0
1	2.0	0.375839	Hipermercado Carrefour	0.0	1.0	0.0	0.0	0.0
2	2.0	-0.053691	Hipermercado Carrefour	0.0	1.0	0.0	0.0	0.0
3	2.0	0.120805	Hipermercado Carrefour	0.0	1.0	0.0	0.0	0.0
4	2.0	0.053691	Hipermercado Carrefour	0.0	1.0	0.0	0.0	0.0

5 rows × 36 columns

Target `cadena`

Ahora aplicamos el Label Encoder a tipo_cadena, que es nuestro target. Siendo 0 Disco, 1 Hipermercados Carrefour y 2 Supermercados Dia.

In [68]:
```
cadenas = precios_claros.cadena.unique()
print("Unidades de presentacion unicas: ")
for cadena in cadenas:
    print(f"\t- {cadena}")
```

```
Unidades de presentacion unicas:
        - Hipermercado Carrefour
        - Supermercados DIA
        - Disco
```

In [69]:
```
from sklearn.preprocessing import LabelEncoder

df = precios_claros
variable = 'cadena'

df[variable] = LabelEncoder().fit_transform(df[variable])
df.head()
```

Out[69]:

	presentacion	precio	cadena	unidad_presentacion	categoria_Agua	categoria_Arroz	categoria_Harinas	categoria_Leche
0	2.0	-0.026846	1	0.0	1.0	0.0	0.0	0.0
1	2.0	0.375839	1	0.0	1.0	0.0	0.0	0.0
2	2.0	-0.053691	1	0.0	1.0	0.0	0.0	0.0
3	2.0	0.120805	1	0.0	1.0	0.0	0.0	0.0
4	2.0	0.053691	1	0.0	1.0	0.0	0.0	0.0

5 rows × 36 columns

6 - MODELO

Hacemos un primer modelo de regresion logistica mediante cross validation, ajustando el parametro para obtener un mejor accuracy. Lo que hace es:

- divide el conjunto de datos en un conjunto de entrenamiento y un conjunto de prueba.
- ajusta el modelo, hace predicciones y calcula una puntuación
- repite el proceso 10 veces en total
- genera el promedio de las 10 puntuaciones

In [70]:
```
from sklearn.model_selection import cross_validate
from sklearn.linear_model import LogisticRegression

X = precios_claros.drop(columns = "cadena")
y = precios_claros["cadena"]

model = LogisticRegression(max_iter=1000)


cv_results = cross_validate(model, X, y, cv=10)

base_model_score = cv_results['test_score'].mean()
print(f" En este primer modelo se obtuvo un accuracy de {round(base_model_score, 4)}")
```

```
 En este primer modelo se obtuvo un accuracy de 0.8005
```

Ahora aplicamos el `train_test_split` y le indicamos el tamaño que queremos para que se entrene el modelo y se prube, en este caso el tamaño de prueba es 0.3, por lo tanto el de entrenamiento es de 0.7

In [71]:
```
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.3, random_state = 10)

model = LogisticRegression()

model.fit(X_train, y_train)

y_pred = model.predict(X_test)

train_test = model.score(X_test, y_test)

print(f"Realizamos un train y test mara mejorar nuestro modelo y obtuvimos un score de: {round(train_test, 4)},
```

```
Realizamos un train y test mara mejorar nuestro modelo y obtuvimos un score de: 0.8343, pudiendo ver que mejoro nuestro modelo en 0.0338
/Users/usuario/PycharmProjects/pythonProject5/POO/lib/python3.9/site-packages/sklearn/linear_model/_logistic.py:444: ConvergenceWarning: lbfgs failed to converge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.

Increase the number of iterations (max_iter) or scale the data as shown in:
    https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver options:
    https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
  n_iter_i = _check_optimize_result(
```

Repetimos el `train_test_split` anterior, pero en esta instancia estratificamos nuestro target, es decir, buscamos que cada conjunto contenga aproximadamente el mismo porcentaje de muestras de cada clase objetivo que el conjunto completo.

In [72]:
```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.3, stratify = y, random_state = 10)
model = LogisticRegression()
model.fit(X_train, y_train)
y_pred = model.predict(X_test)

stratify_score = model.score(X_test, y_test)

print(f'Estratificamos nuestra variable target obteniendo un accuracy {round(stratify_score, 4)}, mejorado un {
```

```
Estratificamos nuestra variable target obteniendo un accuracy 0.8536, mejorado un 0.0193 con respecto al anterior
/Users/usuario/PycharmProjects/pythonProject5/POO/lib/python3.9/site-packages/sklearn/linear_model/_logistic.py:444: ConvergenceWarning: lbfgs failed to converge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.

Increase the number of iterations (max_iter) or scale the data as shown in:
    https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver options:
    https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
  n_iter_i = _check_optimize_result(
```

Utilizamos la funcion para establecer cuales son las variables con mayor influencia en nuestro modelo. A estas variables les llamaremos variables "fuertes", y mediante un umbral seleccionaremos aquellas que nos quedaremos en nuestro modelo.

In [73]:
```
from sklearn.model_selection import cross_val_score
from sklearn.inspection import permutation_importance

print(f"Antes de la permutacion, el score del model es: {round(stratify_score,4)}")

model = LogisticRegression().fit(X,y)
permutation_score = permutation_importance(model, X, y, n_repeats=100)
importance_df = pd.DataFrame(np.vstack((X.columns,
                                        permutation_score.importances_mean)).T,
                             columns = ['feature','feature_importance'])

print("Despues de la permutacion de variables, asi decrece el score en terminos de variables:")
importance_df = importance_df.sort_values(by="feature_importance", ascending = False)
importance_df
```

```
/Users/usuario/PycharmProjects/pythonProject5/POO/lib/python3.9/site-packages/sklearn/linear_model/_logistic.py:444: ConvergenceWarning: lbfgs failed to converge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.

Increase the number of iterations (max_iter) or scale the data as shown in:
    https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver options:
    https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
  n_iter_i = _check_optimize_result(
Antes de la permutacion, el score del model es: 0.8536
Despues de la permutacion de variables, asi decrece el score en terminos de variables:
```

Out[73]:

	feature	feature_importance
33	tipo_cadena_Hipermercado	0.105599
34	tipo_cadena_Supermercado	0.045188
32	tipo_cadena_Autoservicio	0.039832
1	precio	0.00878
0	presentacion	0.003702
21	marca_LA SERENÍSIMA	0.003569
3	categoria_Agua	0.003493
7	categoria_Pastas	0.002822
5	categoria_Harinas	0.002337
23	marca_MAIZENA	0.002105
18	marca_KIN	0.001822
2	unidad_presentacion	0.001747
22	marca_LUCCHETTI	0.00151
20	marca_LA SALTEÑA	0.001353
9	marca_ARMONÍA	0.001324
10	marca_BONAQUA	0.001099
6	categoria_Leche	0.00092
11	marca_CAÑUELAS	0.000636
30	marca_VILLA DEL SUR	0.000497
15	marca_GALLO	0.000463
24	marca_MATARAZZO	0.000457
29	marca_SER	0.000445
27	marca_PUREZA	0.000376
31	marca_VILLAVICENCIO	0.000214
26	marca_NESTLÉ	0.00011
19	marca_KNORR	0.000081
12	marca_DON VICENTE	0.000075
13	marca_ECO DE LOS ANDES	0.000058
17	marca_GLACIAR	0.000058
25	marca_MOLINOS ALA	0.000012
14	marca_FAVORITA	0.000012
28	marca_QUAKER	0.0
8	marca_ARCOR	-0.000093
4	categoria_Arroz	-0.000908
16	marca_GIACOMO	-0.001284

Pasamos al tipo de dato numerico para poder graficar.

In [74]:
```
importance_df = importance_df.set_index("feature")
importance_df.feature_importance = pd.to_numeric(importance_df.feature_importance)
```

In [75]:
```
importance_df.feature_importance.nlargest(10).plot(kind='barh', color = "violet")
plt.show()
print("Vemos que Hipermercado es la mas importante, seguida de Supermercado y Autoservicio")
```

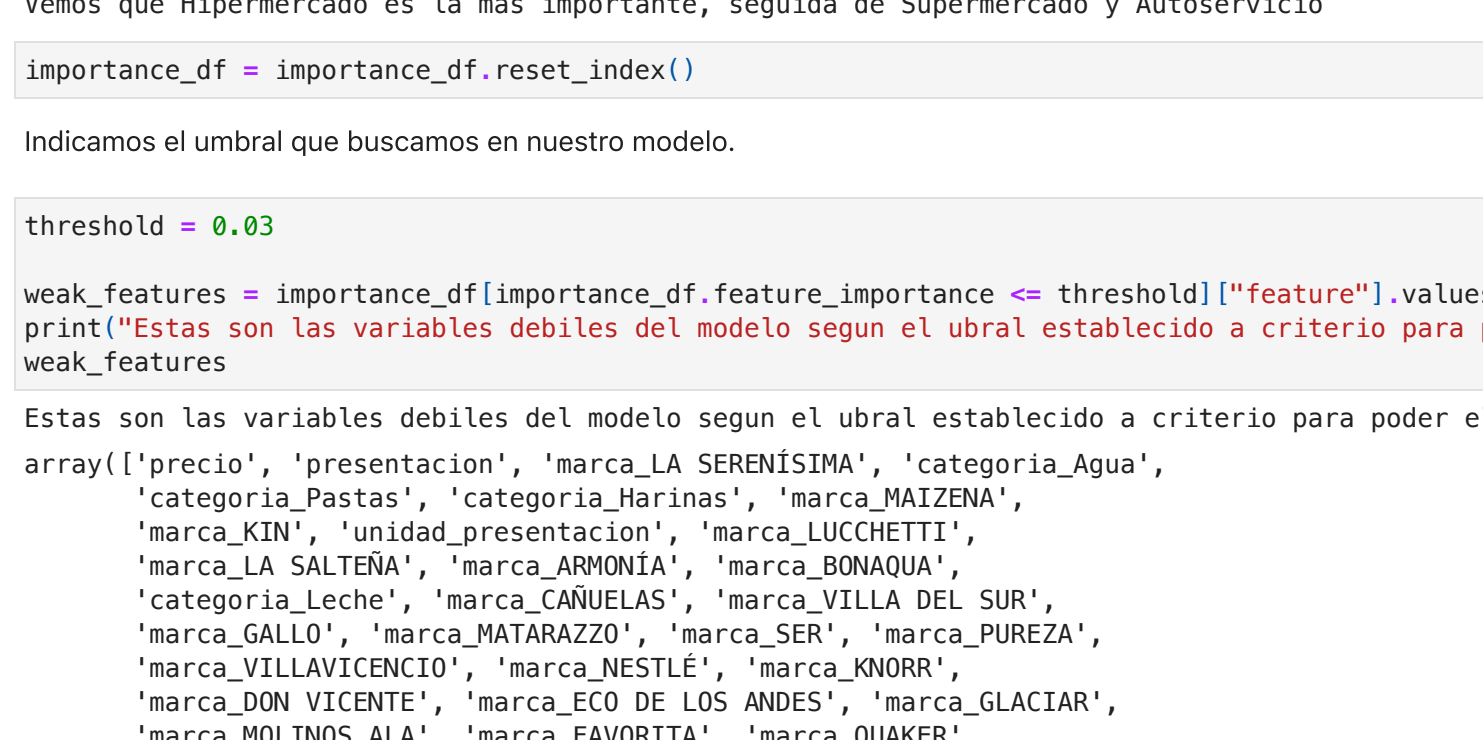


```
Vemos que Hipermercado es la mas importante, seguida de Supermercado y Autoservicio
```

In [76]:
```
importance_df = importance_df.reset_index()
```

Indicamos el umbral que buscamos en nuestro modelo.

In [77]:
```
threshold = 0.03

weak_features = importance_df[importance_df.feature_importance <= threshold]["feature"].values
print("Estas son las variables debiles del modelo segun el ubral establecido a criterio para poder elevar el sc
weak_features
```

```
Estas son las variables debiles del modelo segun el ubral establecido a criterio para poder elevar el score:
```

Out[77]:
```
array(['precio', 'presentacion', 'marca_LA SERENÍSIMA', 'categoria_Agua',
       'categoria_Pastas', 'categoria_Harinas', 'marca_MAIZENA',
       'marca_KIN', 'unidad_presentacion', 'marca_LUCCHETTI',
       'marca_LA SALTEÑA', 'marca_ARMONÍA', 'marca_BONAQUA',
       'categoria_Leche', 'marca_CAÑUELAS', 'marca_VILLA DEL SUR',
       'marca_GALLO', 'marca_MATARAZZO', 'marca_SER', 'marca_PUREZA',
       'marca_VILLAVICENCIO', 'marca_NESTLÉ', 'marca_KNORR',
       'marca_DON VICENTE', 'marca_ECO DE LOS ANDES', 'marca_GLACIAR',
       'marca_MOLINOS ALA', 'marca_FAVORITA', 'marca_QUAKER',
       'marca_ARCOR', 'categoria_Arroz', 'marca_GIACOMO'], dtype=object)
```

Corremos el modelo con las variables fuertes:

In [78]:
```
X_strong_features = df.drop(columns=list(weak_features) + ["cadena"])
print(f"Las variables fuertes son:")
for feature in X_strong_features:
    print(f"\t- {feature}")
```

```
Las variables fuertes son:
        - tipo_cadena_Autoservicio
        - tipo_cadena_Hipermercado
        - tipo_cadena_Supermercado
```

In [79]:
```
model = LogisticRegression()

scores = cross_val_score(model, X_strong_features, y, cv = 10)
strong_model_score = scores.mean()

print(f"Antes de remover las variables el Accurracy es {round(base_model_score, 4)}")

print(f"El modelo entrenado con las variables fuertes dan un accuracy de {round(strong_model_score, 4)}, se pue
```

```
Antes de remover las variables el Accurracy es 0.8005
El modelo entrenado con las variables fuertes dan un accuracy de 0.8571, se puede ver que nuestro accuracy subio en 0.0036
```

Aplicamos el train y test estratificado con las variables fuertes.

In [80]:
```
X_train, X_test, y_train, y_test = train_test_split(X_strong_features, y, test_size = 0.3, stratify = y, random
model = LogisticRegression()
model.fit(X_train, y_train)
y_pred = model.predict(X_test)

stratify_score_strong_features = model.score(X_test, y_test)

print(f'Haciendo el train y test estratificado con las variables fuertes el score obtenido fue de {round(strati
```

```
Haciendo el train y test estratificado con las variables fuertes el score obtenido fue de 0.8671, mejorado un 0.0099 con respecto al anterior.
```

Matriz de confusion

Sabiendo que 0 es Disco, 1 Carrefour y 2 Dia, mediante la matriz de confusion podemos ver cuanto acierta nuestro modelo. Esto se ve en la diagonal de nuestra matriz, mientras qe los valores fuera de la diagonal representa las malas predicciones del modelo.

In [81]:
```
from sklearn.metrics import confusion_matrix

confusion = confusion_matrix(y_test, y_pred)

print(confusion)
```

```
[[ 73   0   0]
 [ 33 347   0]
 [ 36   0  30]]
```

Armamos un reporte de la clasificacion:

- Accuracy es el porcentaje de los aciertos en la prediccion con respecto a los datos reales.
- Recall habla de cuan completos son los resultados, es decir, del total de cada categoria observados, cuantos predijo correctamente de esa categoria.
- Precision habla de cuan utiles son los resultados, es decir, el total de cada categoria predecidos, cuantos predijo correctamente de esa categoria.

In [82]:
```
from sklearn.metrics import classification_report

print(classification_report(y_test, y_pred))
```

```
              precision    recall  f1-score   support

           0       0.51      1.00      0.68        73
           1       1.00      0.91      0.95       380
           2       1.00      0.45      0.62        66

    accuracy                           0.87       519
   macro avg       0.84      0.79      0.75       519
weighted avg       0.93      0.87      0.87       519
```

Podemos ver que el precision y recall de la ultima categoria, Dia (2), son considerablemente menores al de las otras dos categorias de cadenas, Disco (0) y Carrefour (1).

In [83]:
```
import matplotlib.pyplot as plt
from sklearn.model_selection import learning_curve
import numpy as np
train_sizes, train_scores, test_scores = learning_curve(estimator = LogisticRegression(max_iter=100),
                                                         X = X,
                                                         y = y,
                                                         train_sizes = [25,50,75,100,300,400],
                                                         cv = 10)

train_scores_mean = np.mean(train_scores, axis=1)
test_scores_mean = np.mean(test_scores, axis=1)

plt.plot(train_sizes, train_scores_mean, label = 'Training score')
plt.plot(train_sizes, test_scores_mean, label = 'Test score')
plt.ylabel('Accuracy score', fontsize = 14)
plt.xlabel('Training set size', fontsize = 14)
plt.title('Learning curves', fontsize = 18, y = 1.03)
plt.legend()
print("Vemos el pico de accuracy del test score se alcanza con un training size de 300. Viendo la diferencia de
```

```
/Users/usuario/PycharmProjects/pythonProject5/POO/lib/python3.9/site-packages/sklearn/linear_model/_logistic.p
y:444: ConvergenceWarning: lbfgs failed to converge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.

Increase the number of iterations (max_iter) or scale the data as shown in:
    https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver options:
    https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
  n_iter_i = _check_optimize_result(
/Users/usuario/PycharmProjects/pythonProject5/POO/lib/python3.9/site-packages/sklearn/linear_model/_logistic.p
y:444: ConvergenceWarning: lbfgs failed to converge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.

Increase the number of iterations (max_iter) or scale the data as shown in:
    https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver options:
    https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
  n_iter_i = _check_optimize_result(
/Users/usuario/PycharmProjects/pythonProject5/POO/lib/python3.9/site-packages/sklearn/linear_model/_logistic.p
y:444: ConvergenceWarning: lbfgs failed to converge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.

Increase the number of iterations (max_iter) or scale the data as shown in:
    https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver options:
    https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
  n_iter_i = _check_optimize_result(
/Users/usuario/PycharmProjects/pythonProject5/POO/lib/python3.9/site-packages/sklearn/linear_model/_logistic.p
y:444: ConvergenceWarning: lbfgs failed to converge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.

Increase the number of iterations (max_iter) or scale the data as shown in:
    https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver options:
    https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
  n_iter_i = _check_optimize_result(
/Users/usuario/PycharmProjects/pythonProject5/POO/lib/python3.9/site-packages/sklearn/linear_model/_logistic.p
y:444: ConvergenceWarning: lbfgs failed to converge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.

Increase the number of iterations (max_iter) or scale the data as shown in:
    https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver options:
    https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
  n_iter_i = _check_optimize_result(
/Users/usuario/PycharmProjects/pythonProject5/POO/lib/python3.9/site-packages/sklearn/linear_model/_logistic.p
y:444: ConvergenceWarning: lbfgs failed to converge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.

Increase the number of iterations (max_iter) or scale the data as shown in:
    https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver options:
    https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
  n_iter_i = _check_optimize_result(
/Users/usuario/PycharmProjects/pythonProject5/POO/lib/python3.9/site-packages/sklearn/linear_model/_logistic.p
y:444: ConvergenceWarning: lbfgs failed to converge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.

Increase the number of iterations (max_iter) or scale the data as shown in:
    https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver options:
    https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
  n_iter_i = _check_optimize_result(
/Users/usuario/PycharmProjects/pythonProject5/POO/lib/python3.9/site-packages/sklearn/linear_model/_logistic.p
y:444: ConvergenceWarning: lbfgs failed to converge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.

Increase the number of iterations (max_iter) or scale the data as shown in:
    https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver options:
    https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
  n_iter_i = _check_optimize_result(
/Users/usuario/PycharmProjects/pythonProject5/POO/lib/python3.9/site-packages/sklearn/linear_model/_logistic.p
y:444: ConvergenceWarning: lbfgs failed to converge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.

Increase the number of iterations (max_iter) or scale the data as shown in:
    https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver options:
    https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
  n_iter_i = _check_optimize_result(
/Users/usuario/PycharmProjects/pythonProject5/POO/lib/python3.9/site-packages/sklearn/linear_model/_logistic.p
y:444: ConvergenceWarning: lbfgs failed to converge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.

Increase the number of iterations (max_iter) or scale the data as shown in:
    https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver options:
    https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
  n_iter_i = _check_optimize_result(
/Users/usuario/PycharmProjects/pythonProject5/POO/lib/python3.9/site-packages/sklearn/linear_model/_logistic.p
y:444: ConvergenceWarning: lbfgs failed to converge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.

Increase the number of iterations (max_iter) or scale the data as shown in:
    https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver options:
    https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
  n_iter_i = _check_optimize_result(
```

```
Vemos el pico de accuracy del test score se alcanza con un training size de 300. Viendo la diferencia de las cu
rvas podemos ver que a nuestro modelo le queda mucho por mejorar.
```

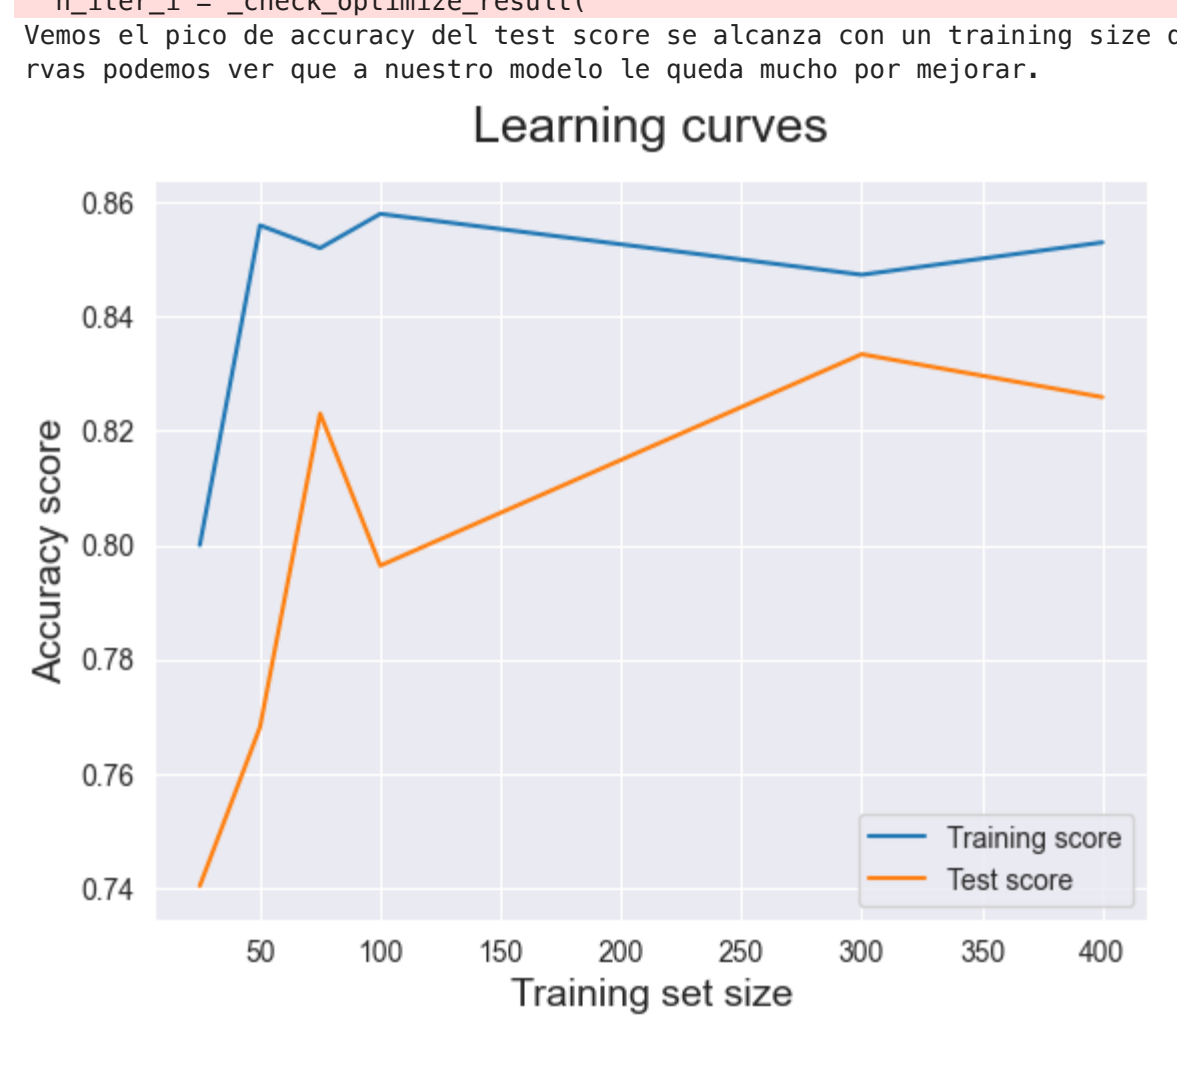

Prediccion de una nueva instancia

Si probamos el modelo usando solo las variables fuertes, podemos ver que solo utilizamos 3 variables: tipo_cadena_Autoservicio, tipo_cadena_Hipermercado y tipo_cadena_Supermercado, que surgen del OneHotEncoder de Tipo de cadena.

In [84]:
```
from sklearn.linear_model import LogisticRegression
from preprocess_tp import cadena

X = df.drop(columns=list(weak_features) + ["cadena"])
y = df["cadena"]
model_pred = LogisticRegression(max_iter=1000)
model_pred.fit(X, y)
X_new = pd.DataFrame({'tipo_cadena_Autoservicio' : [0], 'tipo_cadena_Hipermercado' : [1],
       'tipo_cadena_Supermercado': [0]})
prediction = model_pred.predict(X_new)[0]
print(f"Si nuestro producto es de la cadena Hipermercado, nuestro modelo predice que el producto pertenece a {p
```

```
Si nuestro producto es de la cadena Hipermercado, nuestro modelo predice que el producto pertenece a 1, que es
Hipermercado Carrefour.
```

¿Tiene sentido el resultado?

Si, el resultado tiene mucho sentido, ya que cuando realizamos este grafico en el analisis inicial pudimos ver que cada cadena tiene un tipo de cadena que destaca por sobre la otra y justamente estas son las variables fuertes de nuestro modelo. Es por eso que si le ponemos que es un Autoservicio el modelo va a devolver que es de dia, porque es la unica de las tres cadenas que tiene autoservicios, mientras que si le ponemos que Hipermercado va a devolver que es de Hipermercados carrefour, porque en su mayoria son de tipo Hipermercado, mientras que si ponemos supermercado, probablemente devuelva Disco porque es el unico tipo de cadena que tiene.

A continuacion probamos lo recientemente dicho:

In [85]:
```
from sklearn.linear_model import LogisticRegression
from preprocess_tp import cadena

X = df.drop(columns=list(weak_features) + ["cadena"])
y = df["cadena"]
model_pred = LogisticRegression(max_iter=1000)
model_pred.fit(X, y)
X_new = pd.DataFrame({'tipo_cadena_Autoservicio' : [0], 'tipo_cadena_Hipermercado' : [0],
       'tipo_cadena_Supermercado': [1]})
prediction = model_pred.predict(X_new)[0]
print(f"Si nuestro producto es de la cadena Supermercado, nuestro modelo predice que el producto pertenece a {p
```

```
Si nuestro producto es de la cadena Supermercado, nuestro modelo predice que el producto pertenece a 0, que es
Disco.
```

In [86]:
```
from sklearn.linear_model import LogisticRegression
from preprocess_tp import cadena

X = df.drop(columns=list(weak_features) + ["cadena"])
y = df["cadena"]
model_pred = LogisticRegression(max_iter=1000)
model_pred.fit(X, y)
X_new = pd.DataFrame({'tipo_cadena_Autoservicio' : [1], 'tipo_cadena_Hipermercado' : [0],
       'tipo_cadena_Supermercado': [0]})
prediction = model_pred.predict(X_new)[0]
print(f"Si nuestro producto es de la cadena Autoservicio, nuestro modelo predice que el producto pertenece a {p
```

```
Si nuestro producto es de la cadena Autoservicio, nuestro modelo predice que el producto pertenece a 2, que es
Supermercados Dia.
```

CONCLUSION

¿Se cumple la hipótesis?

La hipotesis establecida al comienzo resulto ser erronea ya que nuestro modelo termino descartando la variable de precio como variable relevante para nuestra prediccion, por lo que el precio no resulto tener una correlacion relevante con la cadena de comercio, por ende tampoco el poder adquisitivo de los consumidores. Al final resulto ser que la variable con mayor influencia fue la del tipo de cadena, ya que en cada cadena predominaba un tipo de cadena en el cual se basa nuestro modelo para predecir si pertenece a Supermercados Dia, Carrefour o Disco.